Université Hassan 1er
Ecole Nationale de Commerce et de Gestion Settat

Rapport

Segmentation des clients selon leur valeur financière

Module :

Encadrée par:
Mr Abderrahim LARHLIMI

Préparé par:
El RHARABY Sanae
EN-NIYARI Basma

Année universitaire: 2026-2027

Introduction générale

Dans le commerce en ligne, tous les clients n'ont pas la même importance : une minorité génère l'essentiel du chiffre d'affaires, tandis que beaucoup n'achètent qu'une ou deux fois. Traiter ces clients de façon uniforme disperse le budget marketing et expose l'entreprise à la perte de ses meilleurs clients. La segmentation RFM répond à ce problème en résumant chaque client par trois indicateurs : la récence de son dernier achat, la fréquence de ses commandes et le montant cumulé de ses dépenses. Les méthodes de classification non supervisée permettent ensuite de regrouper automatiquement les clients qui se ressemblent.

Ce rapport s'appuie sur la base Online Retail de l'UCI, qui contient 541 909 lignes de transactions d'un détaillant en ligne britannique, entre le 1er décembre 2010 et le 9 décembre 2011, pour 4 372 clients identifiés. Il cherche à répondre à la problématique suivante :
Peut-on regrouper les clients d'un détaillant en ligne en segments homogènes, stables et exploitables selon leur valeur financière (récence, fréquence, montant), afin de cibler les actions marketing et de fidélisation ?

L'intérêt est financier. Des segments bien identifiés permettent de mesurer la concentration du chiffre d'affaires, d'allouer le budget marketing aux groupes les plus rentables, de repérer les clients de valeur qui cessent d'acheter et de mieux anticiper les revenus. Nous comparons trois méthodes : K-means, la classification ascendante hiérarchique avec le critère de Ward, et les mélanges gaussiens. Elles sont évaluées par des critères internes, par la stabilité des groupes sur des sous-échantillons et par une validation chronologique sur la dépense future, qui évite toute fuite de données.

Le rapport suit la démarche de notre programme Python, exécutable dans Google Colab, en sept parties. La première présente la collecte et le chargement des données. La deuxième traite de l'audit qualité et du nettoyage. La troisième construit la matrice RFM par client. La quatrième explore la concentration du chiffre d'affaires et prépare les variables. La cinquième décrit la modélisation et le choix de la méthode. La sixième interprète les segments et les valide dans le temps. La septième formule des recommandations opérationnelles et discute les limites de l'étude

I. Données et préparation

1.Préparation et structuration des données au service de la segmentation RFM:

La première étape de la démarche analytique repose sur l'acquisition et la préparation minutieuse du jeu de données transactionnelles (Online Retail). Cette phase est critique : la fiabilité de la segmentation RFM (Récence, Fréquence, Montant) dépend directement de la qualité des données sous-jacentes.

- **Acquisition et robustesse du flux :** La fonction charger_donnees met en œuvre une stratégie d'ingestion à double niveau. Elle privilégie la lecture d'un fichier local au format Excel (.xlsx) pour optimiser les temps de traitement, tout en intégrant une solution de secours (fallback) automatisée via le dépôt ucimlrepo. Cette architecture garantit la reproductibilité absolue du pipeline d'analyse, indépendamment de l'environnement d'exécution.
- **Typage strict et intégrité structurelle :** Afin d'éviter toute altération sémantique lors des calculs ultérieurs, un typage explicite est appliqué dès l'importation :

Identifiants (InvoiceNo, StockCode) : Convertis en chaînes de caractères (texte) pour préserver les préfixes alphanumériques (ex. codes d'annulation ou références d'articles spécifiques) et éviter qu'ils ne soient traités à tort comme des variables numériques.

Temporalité (InvoiceDate) : Convertie au format horodaté (datetime). Ce typage est essentiel pour calculer la Récence (nombre de jours écoulés depuis le dernier achat par rapport à une date de référence).

- Audit de la qualité des données et documentation : Pour formaliser l'état de la base de données avant modélisation, le script génère automatiquement un rapport d'audit exporté dans le fichier 01_description_variables.csv. Ce tableau de bord documentaire consigne pour chaque variable :

-Sa description fonctionnelle et son type de donnée ajusté.

-Le volume de valeurs non nulles et le taux exact d'incomplétude (% de données manquantes), identifiant notamment l'absence potentielle d'identifiants clients (Customer ID).

-La cardinalité (nombre de valeurs distinctes) et un échantillon représentatif de valeurs (exemple), permettant d'anticiper les opérations de filtrage et d'imputation requises.

2.Volumétrie générale et caractéristiques de la base transactionnelle :

L'exploration initiale de la base de données révèle un volume d'informations d'une grande richesse, couvrant un cycle annuel complet d'activité e-commerce.

Métrique	Valeur	Portée analytique pour la segmentation RFM
Volume de transactions	541 909 lignes	Assure une représentativité statistique élevée pour l'entraînement des modèles de clustering (K-Means, segmentation hiérarchique).
Variables disponibles	8 attributs	Permet d'isoler les dimensions nécessaires au calcul du score RFM (facture, produit, quantité, date, prix unitaire, client, pays).
Période d'observation	01/12/2010 – 09/12/2011	Couvre plus de 12 mois consécutifs, intégrant la saisonnalité des ventes (notamment les pics de fin d'année).
Base clients identifiés	4 372 clients	Constitue le périmètre exact d'analyse de la valeur financière individuelle.
Catalogue produits	4 070 références	Démontre une forte diversité de l'offre et des comportements d'achat au panier.
Empreinte géographique	38 pays	Révèle une dimension internationale nécessitant une attention particulière sur la valeur d'achat selon les marchés.
Volume de commandes	25 900 factures	Sert de base directe pour évaluer la Fréquence d'achat moyenne par client.

Tableau 1 : Syntèse de la volumétrie générale de la base de données transactionnelle

3.Synthèse analytique des résultats:

L'analyse de cette volumétrie confirme la faisabilité et la pertinence d'un regroupement des clients en segments homogènes :

1. **Calcul de la Récence et de la Fréquence :** L'amplitude temporelle (plus de 370 jours) et le volume de 25 900 factures permettent de mesurer précisément la récurrence des achats et la fidélité de chaque consommateur au fil du temps.
2. **Calcul du Montant :** Le croisement entre les quantités achetées, les prix unitaires et les 4 372 clients uniques permet de reconstituer le chiffre d'affaires cumulé par individu et de déterminer sa valeur financière (Customer Lifetime Value).
3. **Ciblage stratégique :** La présence de 4 372 clients distincts offre une granularité idéale : le portefeuille est suffisamment vaste pour identifier des profils contrastés (ex. Clients VIP / Champions, Clients réguliers, Clients en sommeil, Clients à risque d'attrition), tout en restant opérationnel pour l'exécution d'actions marketing ciblées et personnalisées.

II. Nettoyage et assainissement des données transactionnelles

Après la phase initiale de cadrage et de description des variables, l'étape de nettoyage constitue un préalable indispensable pour garantir la validité statistique du modèle RFM. Les transactions brutes d'un détaillant en ligne contiennent inévitablement des bruits, des enregistrements administratifs et des valeurs aberrantes qui fausseraient l'évaluation de la valeur financière réelle des clients.

1. Traitements et filtres appliqués par le script :

Afin d'obtenir une base saine et exclusivement centrée sur le comportement d'achat de marchandises, le script applique une séquence rigoureuse de nettoyage en cinq étapes successives :

1.Suppression des doublons : Élimination des enregistrements strictement identiques présents dans les transactions brutes.

2.Suppression des transactions anonymes (absence de CustomerID) : Les lignes dépourvues d'identifiant client ne permettent pas d'agréger les comportements à l'échelle individuelle, rendant impossible leur attribution dans une segmentation RFM.

3.Filtrage des codes non-produits : Élimination des frais annexes, ajustements comptables et commissions de plateforme qui ne traduisent pas un achat de marchandises (codes de frais de port POST, ajustements D, M, B, S, frais bancaires, commissions Amazon, etc.).

4.Exclusion des annulations, retours et valeurs négatives/nulles : Suppression ou isolation des factures d'annulation (identifiables par le préfixe « C » ou des quantités/prix inférieurs ou égaux à zéro).

5.Génération de la variable Montant : Calcul final du chiffre d'affaires brut par ligne transactionnelle (Montant = Quantity X UnitPrice).

2. Bilan quantitatif de la filtration :

Le tableau ci-dessous récapitule l'impact de chaque étape de nettoyage sur le volume global de la base de données :

Étape	Lignes restantes
Données brutes	541 909
Après suppression des doublons	536 641
Avec identifiant client	401 604
Hors codes de frais	399 823
Lignes de vente retenues	391 283
Lignes d'annulation conservées	8 507

Tableau 2 : Flux de nettoyage

L'audit révèle 135 080 lignes sans identifiant client (24,9 %), 5 268 doublons exacts, 9 288 lignes d'annulation, 2 517 prix nuls ou négatifs et 2 771 lignes de codes non produits (port, commission, ajustements). Les règles suivantes sont appliquées, dans cet ordre :

•suppression des doublons exacts ;

•suppression des lignes sans identifiant client, car non segmentables ;

•exclusion des codes de frais (POST, D, M, DOT, BANK CHARGES, etc.), qui ne sont pas des achats de produits ;

•séparation des ventes (quantité et prix positifs) et des annulations, conservées pour mesurer un taux d'annulation par client.

3. Interprétation analytique et portée des choix de filtrage

Le processus de nettoyage conduit à la conservation de **391 283 lignes de vente**, soit environ **72,2 %** du volume initial. Cette réduction est justifiée par la nécessité d'étudier des comportements d'achat réels et qualifiés :

- **Incapacité d'imputation et pertinence RFM :** Le filtrage des transactions sans identifiant client représente la baisse la plus massive (passage de 536 641 à 401 604 lignes). Bien qu'elles génèrent du chiffre d'affaires global, leur exclusion est impérative pour la méthode RFM qui exige une traçabilité individuelle stricte.
- **Cumul non linéaire des anomalies :** Les volumes de suppression s'imbriquent parfois, une même ligne pouvant cumuler plusieurs anomalies (par exemple, un code de frais ou une annulation sans identifiant client).
- **Portée stratégique du calcul financier :** L'isolation des 8 507 lignes d'annulation permet de purifier le chiffre d'affaires. Les montants retenus mesurent ainsi l'intention d'achat brute et l'engagement commercial initial de chaque client envers l'enseigne.

III. Construction du matrice RFM et agrégation à l'échelle client

L'étape d'agrégation transactionnelle constitue le cœur méthodologique de la préparation des données. Elle vise à transformer un historique de transactions individuelles (au niveau de la ligne de commande) en un tableau de synthèse centré sur l'individu, où chaque client est caractérisé par un unique vecteur à trois dimensions : Récence, Fréquence et Montant.

1. Traitement algorithmique et métriques calculées :

La fonction construire_features regroupe les ventes valides par identifiant client (CustomerID) et dérive les trois indicateurs RFM, complétés par trois variables auxiliaires (NbProducts, Anciennete, AvgBasket) et par le taux d'annulation (ReturnRate). Seuls R, F et M alimentent le clustering.

- Récence (R) : nombre de jours entre le dernier achat du client et la date de référence (10 décembre 2011, lendemain de la dernière facture).
- Fréquence (F) : nombre de factures distinctes du client sur la période (01/12/2010 → 09/12/2011).
- Montant (M) : somme de Quantity × UnitPrice sur les lignes de vente valides. Sont exclus les annulations (factures « C »), les codes non-produits (port, commission, ajustements) et les lignes à quantité ou prix ≤ 0. Les annulations sont suivies séparément via ReturnRate.

La population de 4 334 clients correspond à ceux qui ont au moins une vente valide. Les montants sont donc strictement positifs par construction (minimum : 3,75 £), sans filtre supplémentaire.

2. Analyse descriptive et distribution des variables RFM :

Le tableau statistique ci-dessous récapitule la distribution empirique des trois métriques RFM calculées sur le périmètre des 4 334 clients retenus :

Statistique	Récence (jours)	Fréquence (factures)	Montant (£)	Portée comportementale
Clients	4 334	4 334	4 334	Clients ayant au moins une vente valide
Moyenne	92,23	4,25	2 017,52	Sensible aux valeurs extrêmes
Écart-type	100,18	7,64	8 920,36	Forte dispersion des comportements
Minimum	0	1	3,75	Achat le dernier jour ; 1 facture ; plus petite dépense
25 %	17	1	304,30	25 % ont acheté il y a 17 jours ou moins
Médiane (50 %)	50	2	663,71	Comportement de l'acheteur médian
75 %	142	5	1 631,62	75 % dépensent moins de 1 631,62 £
Maximum	373	206	279 138,02	Client ultra-VIP / B2B

Tableau 3 : Analyse descriptive et distribution des variables RFM

3.Interprétation économique et implications analytiques

- **Périmètre** : [mettre 4 372 seulement après vérification avec le print indiqué plus haut] clients identifiés ont été ramenés à 4 334. Les clients écartés n'avaient aucune vente valide : uniquement des annulations, des codes de frais ou des lignes à prix ou quantité nul ou négatif.

- **Asymétrie du Montant** : la moyenne (2 017,52 £) vaut plus de trois fois la médiane (663,71 £), avec un maximum de 279 138,02 £. Les 20 % de clients les plus dépensiers génèrent 74,6 % du CA et le top 1 % en génère 32 % (Gini ≈ 0,7) : une structure proche du principe de Pareto.

- **Fréquence** : 50 % des clients ont passé au plus 2 commandes sur la période ; certains en cumulent jusqu'à 206.

- **Récence** : la moitié des clients a acheté au cours des 50 derniers jours.

- **Normalisation** : les échelles sont très hétérogènes (récence de 0 à 373 jours, montants jusqu'à plusieurs centaines de milliers de livres) et les valeurs extrêmes sont fortes. Les variables sont donc transformées par log1p (adapté aux valeurs nulles, comme Recency = 0), puis standardisées (StandardScaler) avant le K-means, la CHA et le GMM. Cela réduit l'asymétrie, comme le montrent les histogrammes avant/après de la figure 03.

IV. Exploration et construction des variables

1.Analyse exploratoire

Le chiffre d'affaires est saisonnier, avec un pic en novembre lié à la période de Noël ; décembre 2011 est tronqué au 9. Le Royaume-Uni représente 83 % du chiffre d'affaires (figure 1).

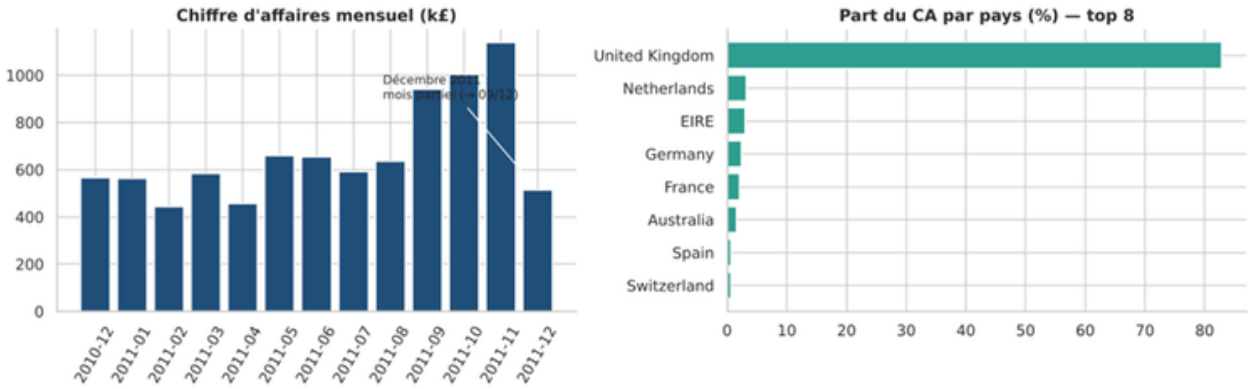


Figure 1: Chiffre d'affaires mensuel et part des principaux pays

La concentration est forte : les 10 % de meilleurs clients réalisent 61 % du chiffre d'affaires, les 20 % 75 % et le 1 % le plus actif 32 % (figure 2). L'indice de Gini atteint 0,72. Quelques clients, vraisemblablement des revendeurs, pèsent un montant très supérieur à la médiane (664 £ contre un maximum de 279 138 £), ce qui impose un traitement des asymétries.

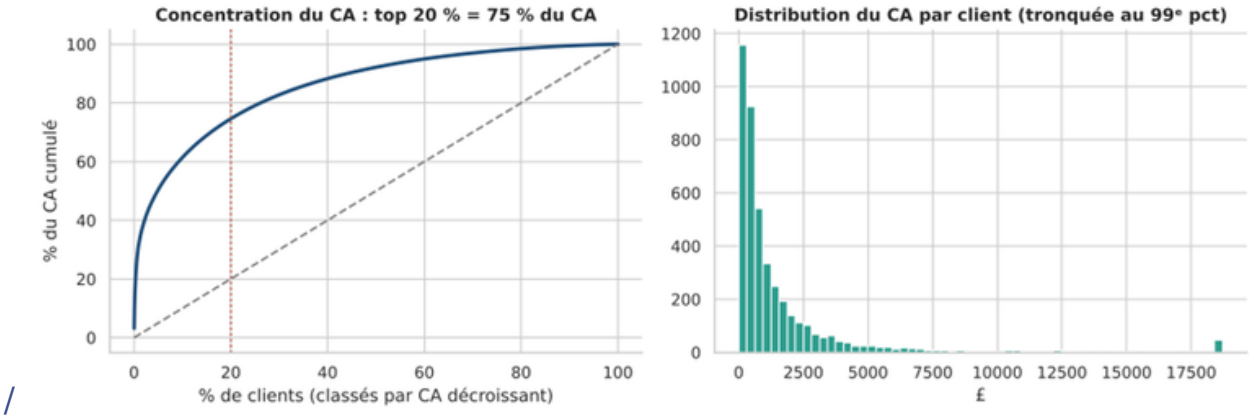


Figure 2 — Concentration du chiffre d'affaires par client

2.Ingénierie des variables

Les variables sont calculées par client à une date de référence fixée au lendemain de la dernière facture (2011-12-10).

Variable	Définition	Lecture financière
Recency	Jours depuis le dernier achat	Risque d'attrition
Frequency	Nombre de factures distinctes	Récurrence
Monetary	Chiffre d'affaires cumulé (£)	Valeur historique
AvgBasket	Monetary / Frequency	Panier moyen
ReturnRate	Montant annulé / montant acheté	Coût de service
NbProducts	Références distinctes achetées	Diversification

Tableau 4 : Variables construites

Le modèle principal utilise les trois variables RFM, classiques et interprétables. Une variante RFM+ ajoute le panier moyen et le taux d'annulation pour tester la robustesse.
Les distributions sont très asymétriques (asymétrie de 12,0 pour la fréquence et 19,6 pour le montant). La transformation log(1+x) ramène ces valeurs à 1,2 et 0,4 (figure 3). Les corrélations de Spearman (figure 4) montrent une forte liaison entre fréquence, montant et nombre de produits, ce qui justifie de ne conserver que la fréquence et le montant dans le modèle principal.

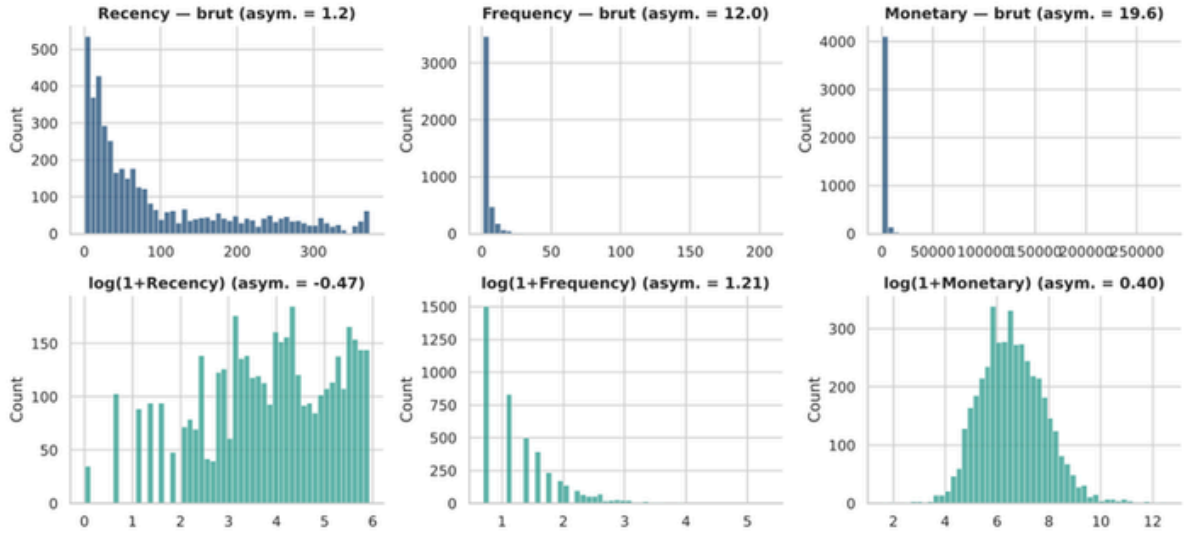


Figure 3: Distributions des variables RFM avant et après transformation logarithmique

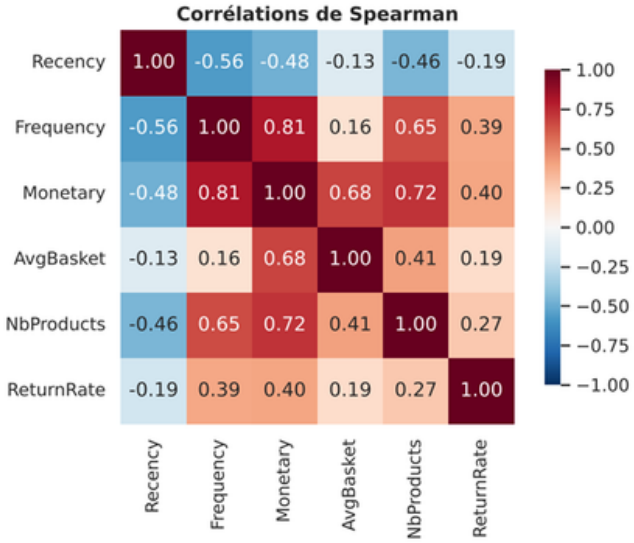


Figure 4: Matrice de corrélations de Spearman

V. Modélisation et choix de la méthode

1.Méthodologie

1.1Pré-traitement et modèles

Les variables sont transformées par log(1+x) puis standardisées, car les trois méthodes reposent sur des distances ou des covariances. Trois approches sont comparées :

• **K-means** (50 initialisations, graine 42) : modèle de référence, rapide, centroïdes lisibles, classes sphériques ;

• **CHA de Ward** : minimise l'augmentation de variance intra-classe, fournit un dendrogramme et ne dépend pas d'une initialisation ;

• **Mélange gaussien** (covariance pleine, régularisation 0,01) : classes ellipsoïdales et affectation probabiliste. La régularisation évite l'effondrement des composantes sur les clients à fréquence 1, dont les valeurs sont identiques.

1.2 Protocole d'évaluation

Le clustering n'a pas de vérité terrain. Quatre niveaux d'évaluation sont donc combinés :

• **critères internes** : inertie, silhouette, Calinski-Harabasz, Davies-Bouldin, BIC et AIC pour le GMM ;

• **stabilité** : 30 sous-échantillons de 80 % des clients ; on mesure l'indice de Rand ajusté (ARI) entre la partition de référence et celle du sous-échantillon ;

• **concordance entre méthodes et entre jeux de variables**(ARI) ;

• **validation chronologique** : segments construits avec les achats jusqu'au 30/09/2011, puis comportement observé du 01/10 au 09/12/2011. Le protocole évite la séparation aléatoire et toute fuite de données.

2.Résultats

2.1 Choix du nombre de segments

La silhouette de K-means est maximale pour K = 2 (0,43) mais cette partition ne distingue que clients actifs et inactifs, trop grossière pour l'action commerciale. Pour K = 4, la silhouette reste de 0,34, l'inertie présente un infléchissement et la stabilité demeure élevée (0,95). Le BIC du GMM décroît jusqu'à K = 8 sans coude net. Les critères ne désignent donc pas un nombre unique : K = 4 est retenu par compromis entre scores, stabilité et lisibilité métier (figures 5 et 6, tableau en annexe).

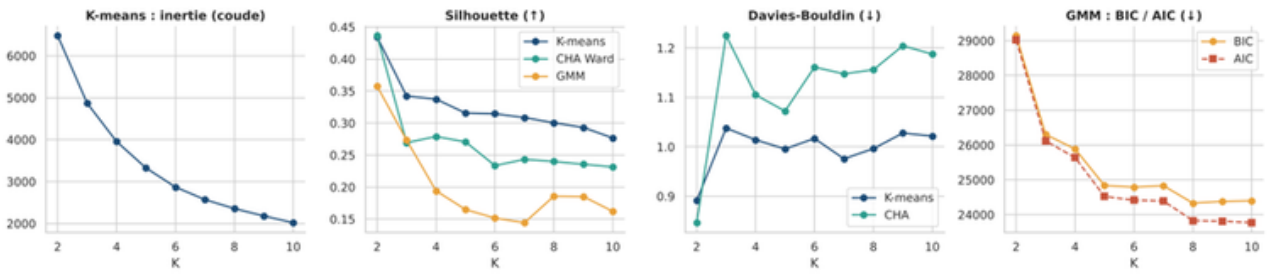


Figure 5: Critères de sélection du nombre de classes

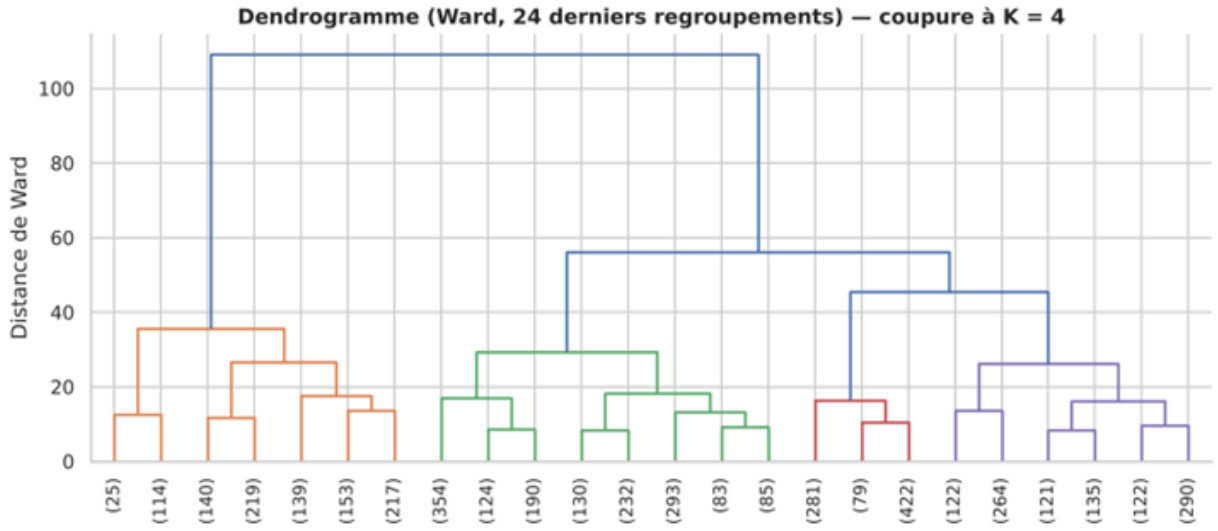


Figure 6: Dendrogramme de Ward tronqué (coupure à K = 4)

2.2 Comparaison des méthodes

Critère (K = 4)	K-means	CHA (Ward)	GMM
Silhouette (↑)	0,338	0,279	0,194
Calinski-Harabasz (↑)	3 300	2 774	2 270
Davies-Bouldin (↓)	1,01	1,11	1,58
Stabilité ARI moyenne (↑)	0,96	0,39	0,88
Taille du plus petit segment (%)	15,9	18,0	13,4

Tableau 5 : Comparaison des trois méthodes pour K = 4

K-means obtient les meilleurs scores internes et la meilleure stabilité. Le GMM est stable (0,88) mais ses classes se chevauchent davantage. La CHA est la moins stable (0,39) : dans le dendrogramme, la coupure à trois ou quatre groupes est ambiguë, et la corrélation cophénétique n'atteint que 0,64. La concordance entre méthodes est modeste (ARI de 0,37 à 0,44) : les clients forment un continuum plutôt que des groupes naturellement séparés, et la partition dépend de la méthode.

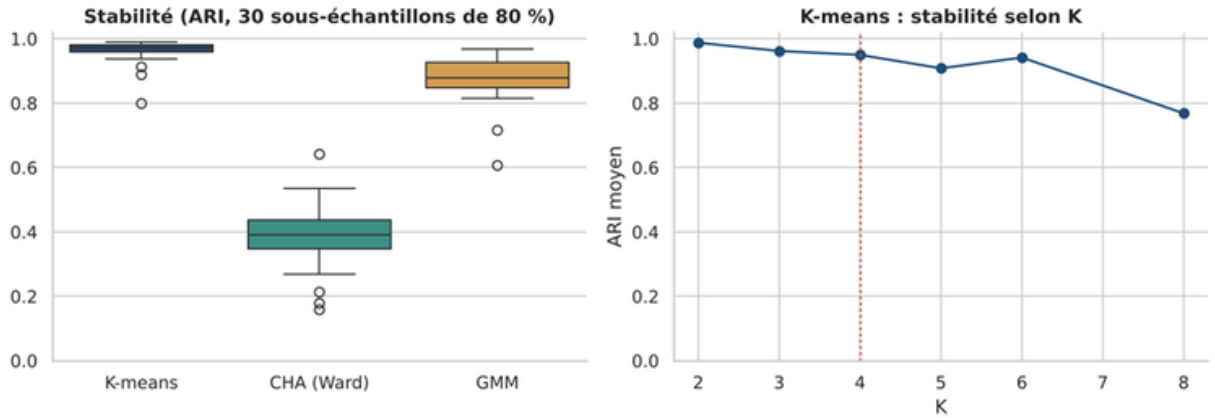


Figure 7: Stabilité des partitions par sous-échantillonnage

La variante RFM+ produit une partition assez différente (ARI de 0,23 avec le modèle RFM) : le choix des variables structure les segments, ce qui doit être documenté dans toute utilisation opérationnelle.

VI. Interprétation et validation des segments

1.Profil des segments (K-means, K = 4)

Indicateur	Champions	Fidèles réguliers	Nouveaux clients	Inactifs / à risque
Clients	688	1 183	813	1 650
Part des clients (%)	15,9	27,3	18,8	38,1
Part du CA (%)	64,2	24,2	5,1	6,5
Récence médiane (jours)	8	53	16	173
Fréquence médiane (factures)	10	4	2	1
CA médian (£)	3 719	1 346	471	296
Panier moyen médian (£)	367	356	228	225
Produits distincts (médiane)	117	60	31	17
Ancienneté médiane (jours)	357	280	70	217
Taux d'annulation moyen (%)	2,2	2,2	1,5	2,2

Tableau 6 : Profil des quatre segments

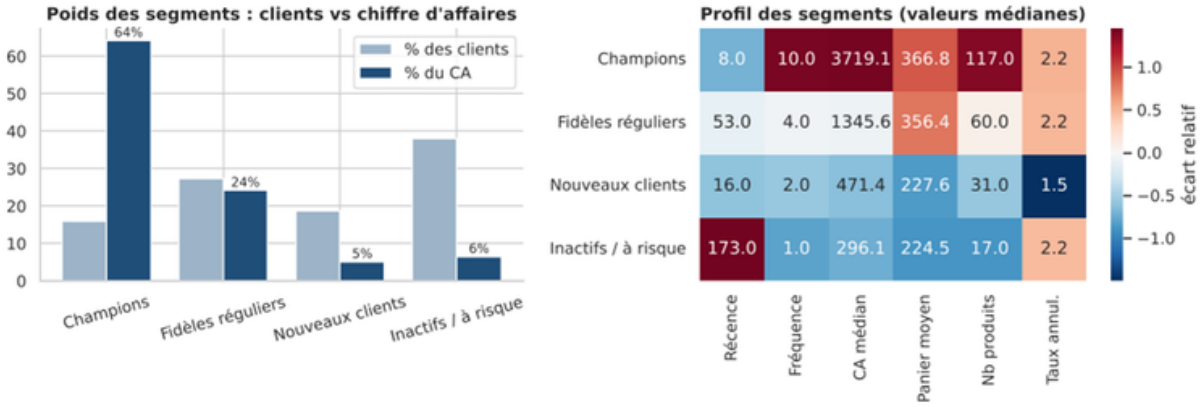


Figure 8 : Poids économique et profil des segments

Les segments sont nommés par des règles lisibles à partir des médianes : Champions (CA médian le plus élevé : 3 719 £, récence 8 jours, 10 factures), Inactifs / à risque (récence la plus élevée : 173 jours), Fidèles réguliers (fréquence la plus élevée parmi les restants) et Nouveaux clients (ancienneté médiane de 70 jours seulement). Les 688 Champions réalisent 64,2 % du chiffre d'affaires, tandis que les 1 650 Inactifs n'en réalisent que 6,5 %. Le taux d'annulation est comparable entre segments (environ 2 %).

2.Lecture dans le plan de l'ACP

Le premier axe de l'ACP explique 75 % de la variance : il oppose l'intensité d'activité (fréquence 0,62, montant 0,60) à la récence (-0,51). Le deuxième axe (19 %) est dominé par la récence. Les segments apparaissent comme des tranches ordonnées d'un continuum, ce qui est cohérent avec la silhouette modérée (figures 9 et 10).

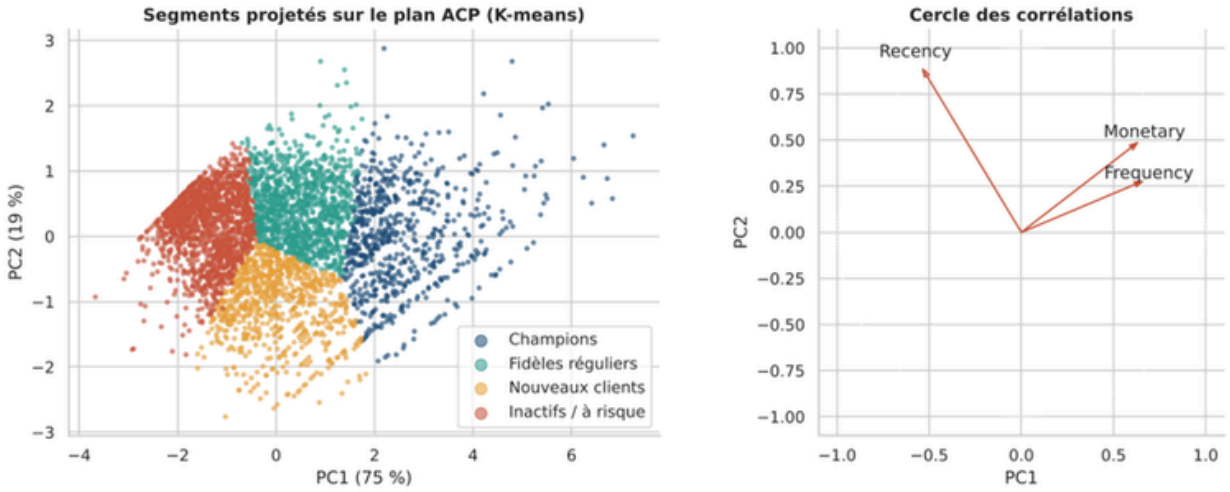


Figure 9 : Segments projetés dans le plan factoriel

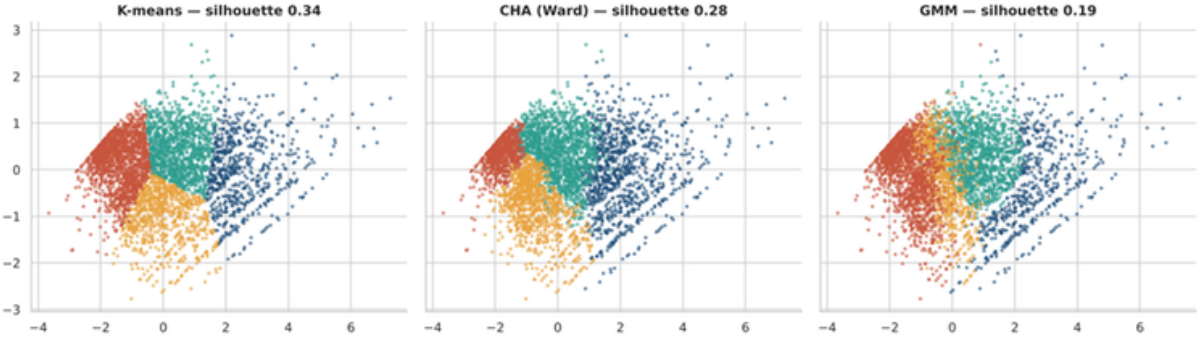


Figure 10 : Comparaison visuelle des trois méthodes

3.Validation chronologique

Les segments sont reconstruits avec les 3 613 clients actifs avant le 1er octobre 2011, puis leur comportement est observé du 1er octobre au 9 décembre 2011, période absente de la construction des segments.

Indicateur	Champions	Fidèles réguliers	Nouveaux clients	Inactifs / à risque
Clients	530	1 030	603	1 450
Taux de réachat (%)	89,3	58,2	51,4	31,5
CA futur moyen par client (£)	2 414	426	292	255
Part du CA futur (%)	56,5	19,4	7,8	16,3

Tableau 7 : Comportement futur par segment

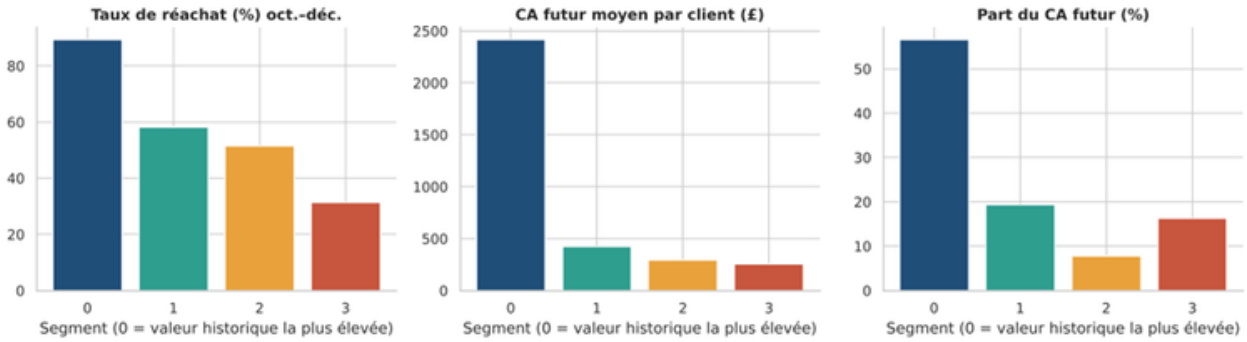


Figure 11 : Réachat et chiffre d'affaires futur par segment (0 = Champions, 3 = Inactifs)

Le gradient est net et monotone : le taux de réachat passe de 89 % à 31 % et le CA futur moyen de 2 414 £ à 255 £. La corrélation de rang entre le numéro de segment et le CA futur vaut -0,47. La période d'observation inclut Noël : les niveaux absolus sont donc gonflés par la saisonnalité, mais le classement relatif des segments reste informatif.

VII . Recommandations, limites

1.Recommandations opérationnelles par segment

Segment	Constat	Action proposée
Champions	16 % des clients, 64 % du CA	Protéger la relation : conseiller dédié, accès anticipé aux nouveautés, alerte si la récence augmente.
Fidèles réguliers	27 % des clients, 24 % du CA	Faire monter en gamme : ventes croisées, paliers de remise sur volume, objectif de passage en Champions.
Nouveaux clients	19 % des clients, ancienneté 70 jours	Obtenir le deuxième achat : parcours d'accueil et relance dans les 30 jours.
Inactifs / à risque	38 % des clients, 6 % du CA	Réactiver à coût plafonné : seuls 31 % rachètent ; éviter de sur-investir.

Tableau 8 : Actions par segment

Le risque de concentration doit aussi être suivi : la perte d'un petit nombre de Champions aurait un effet important sur le chiffre d'affaires.

2.Limites et précautions

•**Fuite de données :** la validation chronologique construit les segments uniquement avec le passé. Une séparation aléatoire aurait surestimé la valeur prédictive.
•**Clients anonymes :** 25 % des lignes n'ont pas d'identifiant. La segmentation ne couvre que les clients identifiés, avec un biais possible.
•**Dérive temporelle et saisonnalité :** douze mois seulement, pic de Noël et décembre 2011 tronqué. La récence dépend de la date de référence.
•**Représentativité :** un seul commerçant, 83 % du chiffre d'affaires au Royaume-Uni, nombreux clients professionnels. Les résultats ne se généralisent pas sans précaution.
•**Dépendance à la méthode et aux variables :** l'ARI entre méthodes (0,34 à 0,44) et entre RFM et RFM+ (0,23) est modeste ; la CHA est instable. Les segments sont une convention d'usage, pas une structure naturelle.
•**Valeur historique différente de la valeur future :** le chiffre d'affaires cumulé n'est pas une valeur vie client (CLV).
•**Usage :** ce projet est pédagogique et ne doit pas servir directement à des décisions financières réelles.

Conclusion

Cette étude montre que la valeur financière de la clientèle est très concentrée. Après nettoyage, 391 283 lignes de vente concernent 4 334 clients : les 20 % de meilleurs clients réalisent 75 % du chiffre d'affaires et l'indice de Gini atteint 0,72. Une segmentation s'impose donc pour allouer les efforts commerciaux.

À partir des variables récence, fréquence et montant, transformées par logarithme puis standardisées, quatre segments ont été retenus avec K-means. Ce choix résulte d'un compromis entre la silhouette (0,34), la stabilité (ARI moyen de 0,96) et la lisibilité métier, car les critères ne désignent pas un nombre de classes unique. K-means obtient de meilleurs résultats que le mélange gaussien (silhouette de 0,19, stabilité de 0,88) et que la classification de Ward (silhouette de 0,28, stabilité de 0,39). Les segments sont :

- Champions : 16 % des clients et 64 % du chiffre d'affaires.
- Fidèles réguliers : 27 % des clients et 24 % du chiffre d'affaires.
- Nouveaux clients : 19 % des clients et 5 % du chiffre d'affaires.
- Inactifs / à risque : 38 % des clients et 6,5 % du chiffre d'affaires.

La validation chronologique confirme leur valeur prédictive. Les segments ont été construits uniquement avec les achats d'avant le 1er octobre 2011, pour 3 613 clients. Entre octobre et décembre 2011, 89 % des Champions rachètent et portent 57 % du chiffre d'affaires futur, contre 31 % de réachat pour les Inactifs. Les recommandations en découlent : protéger les Champions, faire monter les Fidèles en gamme, obtenir le deuxième achat des Nouveaux clients et réactiver les Inactifs avec un budget plafonné.

Ces résultats doivent être interprétés avec prudence. Les données couvrent douze mois, avec l'effet de Noël, et un seul commerçant, dont 83 % du chiffre d'affaires est réalisé au Royaume-Uni. Un quart des lignes, sans identifiant client, ne peut pas être segmenté. Les clients forment un continuum plutôt que des groupes naturellement séparés : la concordance entre méthodes est modeste (ARI de 0,34 à 0,44) et la partition change avec le choix des variables (ARI de 0,23 entre RFM et RFM+). Enfin, le chiffre d'affaires cumulé mesure une valeur historique et non une valeur vie client.

Parmi les prolongements possibles, on peut citer l'allongement de la période d'observation, l'intégration d'un coût de service pour passer de la valeur brute à la rentabilité par segment, et la prévision de la valeur future par un modèle supervisé.